Referencias

Benami, E., Jin, Z., Carter, M. R., Ghosh, A., Hijmans, R. J., Hobbs, A., Kenduiywo, B., & Lobell, D. B. (2021). Uniting remote sensing, crop modelling and economics for agricultural risk management. *Nature Reviews Earth & Environment, 2*(2), 140–159. https://doi.org/10.1038/s43017-020-00122-y

Climate Hazards Center. (2025). *CHIRTS-ERA5 data repository* [Conjunto de datos]. University of California, Santa Barbara. https://doi.org/10.15780/G2F08J

Fideicomisos Instituidos en Relación con la Agricultura (FIRA). (2026). *Reto AgroCebada 2026: Descripción general del conjunto de datos* [Documento técnico proporcionado a los participantes].

Funk, C., Peterson, P., Landsfeld, M., Pedreros, D., Verdin, J., Shukla, S., Husak, G., Rowland, J., Harrison, L., Hoell, A., & Michaelsen, J. (2015). The climate hazards infrared precipitation with stations—a new environmental record for monitoring extremes. *Scientific Data, 2,* Article 150066. https://doi.org/10.1038/sdata.2015.66

Horváth, Á., Berki, Z., Balla, K., Bányai, J., Mayer, M., Cseh, A., Kiss, T., & Karsai, I. (2024). Field versus controlled environmental experiments to evaluate the heat stress response of barley (Hordeum vulgare L.). *Environmental and Experimental Botany, 228,* Article 106038. https://doi.org/10.1016/j.envexpbot.2024.106038

Instituto Nacional de Estadística y Geografía. (2013). *Continuo de Elevaciones Mexicano 4.0* [Modelo digital de elevación]. https://www.inegi.org.mx/app/geo2/elevacionesmex/

Instituto Nacional de Estadística y Geografía. (2026). *Servicio web del Catálogo Único de Claves Geoestadísticas* [Servicio de información geográfica]. Recuperado el 9 de octubre de 2026, de https://www.inegi.org.mx/servicios/catalogounico.html

Iranzo, C., Montorio, R., & García-Martín, A. (2022). Estimación de la producción de cebada a partir de imágenes Sentinel-1, Sentinel-2 y variables climáticas. *Revista de Teledetección, 59,* 61–72. https://doi.org/10.4995/raet.2022.15099

Leukel, J., Zimpel, T., & Stumpe, C. (2023). Machine learning technology for early prediction of grain yield at the field scale: A systematic review. *Computers and Electronics in Agriculture, 207,* Article 107721. https://doi.org/10.1016/j.compag.2023.107721

Meroni, M., Waldner, F., Seguini, L., Kerdiles, H., & Rembold, F. (2021). Yield forecasting with machine learning and small data: What gains for grains? *Agricultural and Forest Meteorology, 308–309,* Article 108555. https://doi.org/10.1016/j.agrformet.2021.108555

Morsink, K., Clarke, D. J., & Mapfumo, S. (2016). *How to measure whether index insurance provides reliable protection* (Policy Research Working Paper No. 7744). World Bank. https://doi.org/10.1596/1813-9450-7744

Petersen, C. T., Langgaard, M. K., & Petersen, S. D. (2023). Yield prediction in spring barley from spectral reflectance and weather data using machine learning. *Soil Use and Management, 39*(2), 975–987. https://doi.org/10.1111/sum.12902

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography, 40*(8), 913–929. https://doi.org/10.1111/ecog.02881

Schauberger, B., Jägermeyr, J., & Gornott, C. (2020). A systematic review of local to regional yield forecasting approaches and frequently used data resources. *European Journal of Agronomy*, *120*, Article 126153. https://doi.org/10.1016/j.eja.2020.126153

Servicio de Información Agroalimentaria y Pesquera (SIAP). (2026). Anuario Estadístico de la Producción Agrícola. Secretaría de Agricultura y Desarrollo Rural. https://nube.agricultura.gob.mx/cierre_agricola/

Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, *67*(2), 301–320. https://doi.org/10.1111/j.1467-9868.2005.00503.x