Estimación parcelaria del rendimiento de cebada mediante referencia municipal y regularización climática

Felipe de Jesús Tecuani Ahuehuetl[1*]; Ana Carolina Neri Ortiz[2] y Kamila Elizabeth Cordova Ortiz[3]

[1]Estudiante de Ingeniería Financiera de la Universidad Politécnica de Puebla / *Capitán del equipo: felipe.tecuanial@uppuebla.edu.mx
[2]Estudiante de Economía de la Benemérita Universidad Autónoma de Puebla
[3]Estudiante de Biología de la Benemérita Universidad Autónoma de Puebla

1 Introducción

La estimación del rendimiento agrícola aporta información para planificar la producción, organizar el abastecimiento y evaluar escenarios de riesgo. Su utilidad depende de que las estimaciones representen la variabilidad del cultivo con un error conocido y en una escala compatible con las decisiones que se pretenden apoyar. La literatura identifica distintas aproximaciones basadas en información meteorológica, observación satelital y modelación, cuyos resultados dependen del cultivo, la región y el horizonte de estimación (Schauberger *et al*., 2020).

En los cereales, la combinación de percepción remota y clima permite examinar relaciones entre el desarrollo del cultivo, su ambiente y el rendimiento. Los estudios de cebada ilustran este potencial: Petersen *et al*. (2023) evaluaron reflectancia y meteorología mediante observaciones multianuales, e Iranzo *et al*. (2022) integraron índices Sentinel y variables climáticas ajustadas al calendario agrícola. Sin embargo, dichos enfoques suelen requerir amplios conjuntos de datos plurianuales y no abordan directamente el desafío de generalizar con muestras reducidas y alta dependencia espacial.

La estimación parcelaria presenta dificultades adicionales. Las diferencias de resolución entre fuentes, la nubosidad y la disponibilidad limitada de rendimientos observados pueden reducir la señal útil para distinguir parcelas. Asimismo, seleccionar entre numerosas variables y modelos con pocos datos exige contrastar cualquier ganancia con referencias sencillas y con un esquema de evaluación acorde al uso previsto (Meroni *et al*., 2021; Roberts *et al*., 2017). Por ello, la precisión debe interpretarse junto con el tamaño de muestra, el horizonte temporal y la estructura espacial de los datos, como destaca la revisión de Leukel *et al*. (2023).

En este contexto, el Reto AgroCebada 2026 de los Fideicomisos Instituidos en Relación con la Agricultura (FIRA) plantea estimar el rendimiento de 197 parcelas georreferenciadas en Hidalgo, Puebla y Tlaxcala durante abril-octubre de 2025. El rendimiento está disponible para 138 parcelas y permanece oculto en 59; los insumos comprenden observación satelital, clima mensual y topografía proporcionados en el Dataset del Reto AgroCebada (FIRA, 2026). Considerando que los datos de rendimiento están limitados a la campaña agrícola 2025 y que no se dispone de información detallada sobre el manejo agronómico de las parcelas, el desafío metodológico consiste en descifrar cuáles variables climáticas ofrecen poder predictivo adicional respecto a la ubicación geográfica, la cual puede interpretarse como un *proxy* de las condiciones ambientales y productivas regionales.

El objetivo de este trabajo fue estimar el rendimiento de las 59 parcelas sin etiqueta disponible y evaluar el aporte de una corrección térmica regularizada sobre una referencia municipal. El problema se abordó como estimación retrospectiva en t/ha, comparando las predicciones fuera del entrenamiento con las de dicha referencia. La evaluación buscó determinar el alcance de la información climática para representar diferencias parcelarias y delimitar las condiciones bajo las cuales resulta pertinente utilizar las estimaciones.

2 Justificación

La necesidad específica consiste en estimar el rendimiento de cebada en grano, expresado en toneladas por hectárea (t/ha), de las parcelas sin dato observado y conocer el error de esa estimación. Una referencia municipal puede describir el contexto productivo, pero resulta insuficiente para distinguir pérdidas o rendimientos excepcionales dentro de una misma zona. La pertinencia del proyecto reside en comprobar si el clima suministrado añade capacidad predictiva a esa referencia, utilizando una formulación parsimoniosa y una comparación explícita.

Para productores y técnicos, los resultados pueden servir como referencia contextual y orientar verificaciones de campo. Para FIRA, instituciones financieras y aseguradoras, podrían complementar la caracterización productiva. La literatura vincula teledetección, modelación y economía en la gestión del riesgo agrícola, pero también exige comprobar qué pérdidas y heterogeneidad representan las estimaciones (Benami *et al*., 2021). El proyecto no evaluó acceso al crédito, indemnizaciones ni rentabilidad; estas aplicaciones requieren validación externa y datos económicos y agronómicos adicionales.

El modelo final prescinde de los índices de vegetación y se basa en la referencia municipal y las temperaturas máximas, ya que los índices espectrales aumentaron la varianza y el riesgo de sobreajuste sin mejorar el desempeño de la referencia base.

3 Objetivos

Objetivo general

Estimar el rendimiento de cebada en t/ha de las 59 parcelas sin valor observado disponible del periodo abril-octubre de 2025 en Hidalgo, Puebla y Tlaxcala, mediante una referencia municipal con corrección climática regularizada y evaluación fuera del entrenamiento.

Objetivos específicos

1. Integrar la información parcelaria, satelital, climática y topográfica suministrada por el reto mediante identificadores y controles documentados.

2. Cuantificar el efecto de las anomalías térmicas mensuales mediante regresión regularizada *ElasticNet* para ajustar la referencia municipal dentro de cada municipio.

3. Comparar su RMSE, MAE y R^2 con la referencia municipal, distinguiendo estabilidad de particiones y limitaciones de generalización.

4. Generar las 59 estimaciones finales tras reajustar el procedimiento con las 138 observaciones disponibles y describir su alcance.

4 Metodología

Datos y preparación

La unidad de análisis fue la parcela. Se integraron 197 registros de nueve municipios; 138 presentaron rendimiento, entre 2.0000 y 5.5900 t/ha, y 59 conservaron la etiqueta oculta. El conjunto objetivo comprende seis municipios con alguna observación de entrenamiento. La distribución de los conjuntos se presenta en el Anexo 1, Figura 1.

La base preparada reúne 1,381 columnas procedentes del Dataset Básico de Sentinel-2 y Landsat, Planet, precipitación CHIRPS, temperaturas CHIRTS-ERA5, elevación y pendiente del CEM (INEGI, 2013). CHIRPS combina información infrarroja y estaciones (Funk *et al*., 2015); CHIRTS-ERA5 aporta temperaturas corregidas y distribuidas en malla de 0.05° (Climate Hazards

Center [CHC], 2025). La integración se realizó en el Sistema de Información Geográfica *QGIS* mediante estadística zonal y uniones por identificador, manteniendo la trazabilidad de cada parcela.

Las observaciones ópticas con una fracción de nubes superior al 20% fueron descartadas, y las imágenes válidas restantes se promediaron temporalmente por mes para atenuar vacíos de información, un umbral operativo estándar en el monitoreo regional de cultivos (Meroni *et al*., 2021). No se identificaron duplicados ni faltantes en los siete predictores finales. No se eliminaron rendimientos extremos. Los insumos ópticos y topográficos formaron parte de la exploración, pero no de la entrada final.

Modelo y ajuste

Se utilizaron las temperaturas máximas medias mensuales de abril a octubre de 2025 y el municipio de cada parcela. En cada entrenamiento se calcularon promedios municipales de rendimiento y temperatura y se estandarizaron las desviaciones térmicas. El rendimiento se estimó mediante la ecuación 1.

$$\hat{y}_i = \bar{y}_{m(i)} + \frac{1}{2}\sum_{k=4}^{10}\beta_k\left(x_{i,k} - \bar{x}_{m(i),k}\right) \qquad \text{Ecuación } (1)$$

Donde $\hat{y}_i$ es el rendimiento estimado, en t/ha; $m(i)$ identifica el municipio; $\bar{y}_{m(i)}$ es su rendimiento promedio de entrenamiento; $x_{i,k}$ y $\bar{x}_{m(i),k}$ son las temperaturas máximas medias del mes de la parcela y del municipio, respectivamente; y β_k es el coeficiente *ElasticNet* desestandarizado, en (t/ha)/°C. Para municipios ausentes del entrenamiento se emplearon promedios globales. La suma comprende abril-octubre.

ElasticNet combina penalizaciones L1 y L2 para tratar predictores correlacionados (Zou & Hastie, 2005). Se evaluaron mezclas de 0.10, 0.50 y 0.90 y 40 intensidades mediante cinco particiones internas. El reajuste final obtuvo alpha = 0.0247492686 y mezcla L1 = 0.1000. La optimización evaluó la corrección completa; el factor 0.50 se aplicó posteriormente. La ecuación y los coeficientes y sus especificaciones se presentan en el Anexo 1 Ecuación 1 y Tabla A1.

Evaluación y selección

Se emplearon cinco particiones externas aleatorias repetidas con semillas 42-51 para comparar candidatos y 52-61 para examinar estabilidad adicional: 100 ajustes externos del procedimiento final. Cada parcela quedó excluida del ajuste que produjo su predicción. Se calcularon métricas sobre las 138 predicciones reunidas de cada repetición y después se resumieron entre repeticiones.

La comparación documentada incluyó 43 variantes. La selección partió del menor RMSE y consideró diferencias medias frente a su variabilidad, seguidas de MAE y estabilidad. Esta regla es heurística, no una prueba formal de equivalencia. La selección de familias y predictores utilizó las mismas observaciones evaluadas; las diez repeticiones adicionales no constituyen una prueba independiente. La evaluación debe interpretarse según el uso espacial previsto (Roberts *et al*., 2017).

Se examinó además un escenario ponderado con municipios representados por al menos dos observaciones. Su exclusión de Nanacamilpa implica que representa 58 de las 59 parcelas objetivo. Un *bootstrap* de 2,000 muestras individuales se consideró descriptivo y condicionado a las predicciones existentes, sin preservar dependencia espacial ni repetir selección.

Contexto municipal y estimación final

Para contextualizar resultados se extrajeron del Servicio de Información Agroalimentaria y Pesquera (SIAP, 2026) registros municipales de 2025 de cebada grano, temporal y primavera-verano. El rendimiento agregado se calculó como producción/superficie cosechada; las medias parcelarias fueron simples. Este contraste descriptivo no se utilizó para entrenar o calibrar el modelo. El procedimiento se reajustó con las 138 etiquetas y generó 59 estimaciones (Anexo 4, Tabla 3).

5 Resultados y discusión

El modelo seleccionado obtuvo RMSE = 0.4948 t/ha, MAE = 0.3319 t/ha y R^2 = 0.6596 en las repeticiones de comparación. Frente al promedio municipal, el RMSE disminuyó aproximadamente 3.47%. Las repeticiones adicionales arrojaron RMSE = 0.4933 t/ha, MAE = 0.3285 t/ha y R^2 = 0.6616 (Anexo 2, Tabla 1). Esta consistencia respalda estabilidad ante las particiones examinadas, aunque las observaciones siguen correspondiendo a una sola campaña.

La mejora fue modesta: la segunda variante difirió aproximadamente 0.0003 t/ha en RMSE. El bootstrap favoreció al modelo en 99.05% de los remuestreos, con intervalo percentil de mejora de 0.0023-0.0387 t/ha, condicionado a predicciones fijas y sin preservar dependencia municipal. Por tanto, la selección respalda una formulación parsimoniosa, sin demostrar superioridad general sobre métodos más complejos. La comparación con referencias sencillas coincide con la recomendación metodológica de Meroni *et al*. (2021).

La composición geográfica explica parte de la ganancia. Los tres municipios con una sola etiqueta aportaron 70.41% de la reducción de suma de errores cuadrados en las repeticiones 42-51. Al ponderar municipios para representar 58 de las 59 parcelas objetivo, el RMSE pasó de 0.4891 a 0.4842 t/ha, mientras que el MAE aumentó de 0.3239 a 0.3257 t/ha. La reducción de errores grandes coexistió, por tanto, con una ligera pérdida en error absoluto medio. El escenario excluye Nanacamilpa y no representa íntegramente el conjunto objetivo.

Las predicciones se concentraron cerca de las medias municipales y atenuaron los extremos (Anexo 2, Figura 3). En las diez repeticiones de comparación se sobreestimaron las 13 parcelas con rendimiento ≤2.5000 t/ha y se subestimaron las 10 con rendimiento ≥5.0000 t/ha. El contexto municipal concentró descriptivamente 68.62% de la variación observada; esa proporción no equivale al desempeño fuera de muestra. Las 59 predicciones finales, redondeadas en el CSV, abarcan 2.5020-4.6384 t/ha; la tabla muestra el mismo producto con cuatro posiciones decimales.

Las estadísticas del SIAP permiten situar esta señal en su contexto territorial. En 2025, los nueve municipios registraron 88,789.7300 ha cosechadas y 230,822.0200 t de cebada grano de temporal en primavera-verano, equivalentes a 2.5996 t/ha como cociente agregado. La media de las 138 parcelas fue 3.9554 t/ha. Estas cifras estiman poblaciones y ponderaciones diferentes; su discrepancia no mide error del modelo ni demuestra un sesgo cuantificable (SIAP, 2026; Anexo 3, Tabla 2).

El contraste tampoco es uniforme entre municipios. Chignahuapan presentó 3.2200 t/ha en SIAP frente a 4.4773 t/ha en las parcelas observadas; Calpulalpan mostró 4.0000 frente a 3.0000 t/ha. En Nanacamilpa, la referencia de 4.0000 t/ha contrasta con una única parcela observada de 2.5000

t/ha (Anexo 3, Figura 4). Estas diferencias justifican comprobar representatividad y comparabilidad antes de extrapolar la referencia de la muestra a todo el municipio. Las cifras del SIAP se utilizan aquí como contexto retrospectivo, no como covariable ni validación parcelaria.

Las temperaturas mensuales correlacionadas describen una señal ambiental conjunta. La literatura experimental muestra respuestas al calor dependientes de etapa y genotipo (Horváth *et al*., 2024), pero la falta de fenología y manejo impide atribuir mecanismos a coeficientes mensuales. La ausencia de mejora óptica se limita a las configuraciones evaluadas: Petersen *et al*. (2023) documentaron utilidad de reflectancia y meteorología con datos multianuales, bajo condiciones distintas.

El aporte demostrado es una referencia parcelaria contextual, trazable y comparada con un estimador simple. Para avanzar en diferencias intramunicipales se requieren medición documentada del rendimiento, fechas agrícolas, manejo y campañas adicionales. La evaluación futura debe incluir toda la selección del procedimiento y corresponder al escenario de aplicación (Roberts *et al*., 2017; Leukel *et al*., 2023).

6 Uso de la ciencia de datos en la inclusión financiera del sector agro

El producto aporta una referencia territorial de productividad que puede integrarse a la evaluación técnica de solicitudes de financiamiento y al seguimiento de carteras agrícolas. Reunir ubicación, rendimiento estimado y contexto municipal facilita identificar unidades que requieren información adicional o visita de campo. Su contribución potencial al sector financiero radica en proporcionar una línea base objetiva de productividad regional para la zonificación preliminar de riesgos en carteras agrícolas donde escasean los registros históricos a escala de parcela.

El contraste con el SIAP ayuda a reconocer que el promedio de las parcelas del reto no representa necesariamente el municipio completo. Por ello, la interpretación financiera debe conservar el ámbito de la muestra. Con un RMSE de 0.4948 t/ha y predominio de señal municipal, resulta razonable comenzar con caracterización territorial y revisión técnica individual, conforme al vínculo entre modelación y gestión del riesgo descrito por Benami *et al*. (2021).

Al incorporar superficie, precios y costos podrían elaborarse escenarios económicos; el rendimiento por sí solo no identifica rentabilidad ni capacidad de pago. Para seguros se requiere estudiar pérdidas, indemnizaciones y riesgo base (Morsink *et al*., 2016). Aunque el modelo no estima la probabilidad de indemnización ni justifica decisiones automáticas, previa validación podría aportar evidencia productiva para la evaluación preliminar del aseguramiento de parcelas. Su contribución potencial a la inclusión financiera consiste en reducir las brechas de información que dificultan evaluar a productores con registros limitados, incluidos quienes carecen de historial crediticio, y ofrecer elementos técnicos complementarios para facilitar su acceso a servicios financieros y seguros agrícolas.

7 Conclusiones

El modelo de referencia municipal con corrección térmica ajustada con ElasticNet generó las estimaciones de las 59 parcelas objetivo. En la validación de comparación obtuvo una raíz del error cuadrático medio (RMSE) de 0.4948 toneladas por hectárea, un error absoluto medio (MAE) de 0.3319 toneladas por hectárea y un coeficiente de determinación (R^2) de 0.6596. Los resultados indican que, con pocas observaciones y sin datos de manejo, la corrección con temperatura máxima mejora ligeramente al promedio municipal. La mayor parte de la variación observada del rendimiento corresponde a diferencias entre municipios (68.62 %).

La ganancia global en la raíz del error cuadrático medio fue cercana al 3.47 %, pero bajó a 0.99 % en el escenario que representa 58 de las 59 parcelas objetivo, donde el error absoluto medio empeoró ligeramente. El procedimiento recupera sobre todo diferencias entre municipios y tiene limitaciones para representar los extremos dentro de cada municipio.

La comparación retrospectiva con el Servicio de Información Agroalimentaria y Pesquera (SIAP) mostró diferencias entre el rendimiento administrativo y las medias de las parcelas del estudio. Por eso, antes de usar las estimaciones como referencia de todo el municipio, hay que comprobar su representatividad. Esos registros no participaron en el modelo ni sustituyen la evaluación con rendimientos reales.

En las configuraciones evaluadas, los índices de vegetación no mejoraron el desempeño respecto al modelo seleccionado. Contar con fechas agrícolas, datos de manejo y campañas adicionales podría mejorar la estimación de diferencias dentro de cada municipio. Complementadas con datos económicos, estas estimaciones podrían apoyar una evaluación rápida de las condiciones productivas de las parcelas como insumo para valorar el riesgo financiero.

Referencias

Benami, E., Jin, Z., Carter, M. R., Ghosh, A., Hijmans, R. J., Hobbs, A., Kenduiywo, B., & Lobell, D. B. (2021). Uniting remote sensing, crop modelling and economics for agricultural risk management. *Nature Reviews Earth & Environment, 2*(2), 140–159. https://doi.org/10.1038/s43017-020-00122-y

Climate Hazards Center. (2025). *CHIRTS-ERA5 data repository* [Conjunto de datos]. University of California, Santa Barbara. https://doi.org/10.15780/G2F08J

Fideicomisos Instituidos en Relación con la Agricultura. (2026). *Reto AgroCebada 2026: Descripción general del conjunto de datos* [Documento técnico proporcionado a los participantes].

Funk, C., Peterson, P., Landsfeld, M., Pedreros, D., Verdin, J., Shukla, S., Husak, G., Rowland, J., Harrison, L., Hoell, A., & Michaelsen, J. (2015). The climate hazards infrared precipitation with stations—a new environmental record for monitoring extremes. *Scientific Data, 2,* Article 150066. https://doi.org/10.1038/sdata.2015.66

Horváth, Á., Berki, Z., Balla, K., Bányai, J., Mayer, M., Cseh, A., Kiss, T., & Karsai, I. (2024). Field versus controlled environmental experiments to evaluate the heat stress response of barley (Hordeum vulgare L.). *Environmental and Experimental Botany, 228,* Article 106038. https://doi.org/10.1016/j.envexpbot.2024.106038

Instituto Nacional de Estadística y Geografía. (2013). *Continuo de Elevaciones Mexicano 4.0* [Modelo digital de elevación]. https://www.inegi.org.mx/app/geo2/elevacionesmex/

Instituto Nacional de Estadística y Geografía. (2026). *Servicio web del Catálogo Único de Claves Geoestadísticas* [Servicio de información geográfica]. Recuperado el 9 de octubre de 2026, de https://www.inegi.org.mx/servicios/catalogounico.html

Iranzo, C., Montorio, R., & García-Martín, A. (2022). Estimación de la producción de cebada a partir de imágenes Sentinel-1, Sentinel-2 y variables climáticas. *Revista de Teledetección, 59,* 61–72. https://doi.org/10.4995/raet.2022.15099

Leukel, J., Zimpel, T., & Stumpe, C. (2023). Machine learning technology for early prediction of grain yield at the field scale: A systematic review. *Computers and Electronics in Agriculture, 207,* Article 107721. https://doi.org/10.1016/j.compag.2023.107721

Meroni, M., Waldner, F., Seguini, L., Kerdiles, H., & Rembold, F. (2021). Yield forecasting with machine learning and small data: What gains for grains? *Agricultural and Forest Meteorology, 308–309,* Article 108555. https://doi.org/10.1016/j.agrformet.2021.108555

Morsink, K., Clarke, D. J., & Mapfumo, S. (2016). *How to measure whether index insurance provides reliable protection* (Policy Research Working Paper No. 7744). World Bank. https://doi.org/10.1596/1813-9450-7744

Petersen, C. T., Langgaard, M. K., & Petersen, S. D. (2023). Yield prediction in spring barley from spectral reflectance and weather data using machine learning. *Soil Use and Management, 39*(2), 975–987. https://doi.org/10.1111/sum.12902

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography, 40*(8), 913–929. https://doi.org/10.1111/ecog.02881

Schauberger, B., Jägermeyr, J., & Gornott, C. (2020). A systematic review of local to regional yield forecasting approaches and frequently used data resources. *European Journal of Agronomy, 120,* Article 126153. https://doi.org/10.1016/j.eja.2020.126153

Servicio de Información Agroalimentaria y Pesquera (SIAP). (2026). Anuario Estadístico de la Producción Agrícola. Secretaría de Agricultura y Desarrollo Rural. https://nube.agricultura.gob.mx/cierre_agricola/

Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B (Statistical Methodology), 67*(2), 301–320. https://doi.org/10.1111/j.1467-9868.2005.00503.x